Introducción

La automatización del aprendizaje automático (AutoML) ha experimentado un notable desarrollo, reduciendo progresivamente la necesidad de intervención experta en tareas como la selección de algoritmos, el ajuste de hiperparámetros y el diseño de flujos de trabajo completos. Sin embargo, el estado actual del arte revela una limitación fundamental: los sistemas AutoML tradicionales operan sobre espacios de búsqueda muy grandes y no aprenden de experiencias previas, de modo que cada nueva tarea se aborda desde cero, desperdiciando el conocimiento que se adquiere en problemas anteriores. Por otra parte, los modelos de lenguaje de gran escala (Large Language Models, LLMs) han mostrado un comportamiento de meta-aprendizaje implícito que los habilita para actuar como meta-aprendices, permitiendo generar pipelines de ML a partir de descripciones textuales y del conocimiento adquirido durante el pre-entrenamiento [1]–[3]. No obstante, dichas capacidades conviven con riesgos significativos: los LLMs alucinan información, generan código incorrecto o no ejecutable, y carecen de mecanismos internos de validación que garanticen la corrección de las soluciones propuestas [4], [5]. Frente a este escenario, la inteligencia artificial neuro-simbólica ofrece un paradigma de integración que combina la flexibilidad de las redes neuronales con el rigor de los sistemas simbólicos, y se presenta como una vía prometedora para construir sistemas AutoML que aprendan de la experiencia y, al mismo tiempo, verifiquen formalmente sus recomendaciones [6]–[8].

El presente trabajo se inscribe en esta intersección y propone una estrategia computacional de meta-aprendizaje basada en el paradigma neuro-simbólico para el dominio de AutoML. La propuesta aprovecha un LLM como generador de pipelines asistido por una base de conocimiento de experiencias previas, y añade un componente simbólico de validación post-generación que garantiza la corrección sintáctica y semántica de los flujos antes de su evaluación empírica. Este capítulo introduce la motivación y justificación del estudio, formula el problema científico, establece la hipótesis de partida, detalla los objetivos y describe la metodología que guiará el desarrollo de la investigación.

1.1 Motivación y Justificación

1.1.1 La necesidad de aprender de la experiencia en AutoML

El campo de AutoML se ha consolidado como un pilar para democratizar el acceso al aprendizaje automático, pero la mayoría de los sistemas más difundidos abordan cada nueva tarea sin aprovechar el conocimiento acumulado en problemas anteriores. Herramientas como Auto-WEKA [6] o TPOT [7] ejecutan búsquedas independientes para cada dataset, partiendo de cero en cada ocasión. Incluso aquellos sistemas que incorporan meta-aprendizaje, como Auto-Sklearn 2.0 [8], suelen limitarlo a una transferencia puramente asociativa: inicializan la búsqueda bayesiana con configuraciones que funcionaron bien en conjuntos de datos con meta-características similares, pero no capturan el razonamiento que justifica por qué ciertas decisiones son adecuadas para determinadas características de los datos. Esta transferencia, basada exclusivamente en la similitud de vectores de meta-características, no aprovecha el conocimiento semántico ni las relaciones causales que un experto humano emplearía al diseñar un flujo de trabajo.

En paralelo, la investigación en modelos de lenguaje de gran escala (LLMs) ha revelado que estos modelos, entrenados con ingentes volúmenes de texto que incluyen documentación de bibliotecas como Scikit-Learn, foros de discusión y repositorios de datasets, almacenan un conocimiento implícito sobre qué algoritmos e hiperparámetros son apropiados para diversos problemas de ML [1], [9]–[11]. Estudios recientes están investigando el alcance de esta capacidad, que puede interpretarse como una forma de meta-aprendizaje implícito: el modelo ha visto suficientes ejemplos de tareas exitosas como para recomendar soluciones razonables sin ajuste adicional [11]. Sin embargo, la naturaleza opaca de dicho aprendizaje y la tendencia a alucinar —inventar nombres de clases, combinar componentes incompatibles o sugerir hiperparámetros fuera de rango— impiden confiar ciegamente en sus recomendaciones [4], [5], [12].

1.1.2 El paradigma neuro-simbólico como candidato

La inteligencia artificial neuro-simbólica propone acoplar un componente neuronal, que aporta flexibilidad y capacidad de generalización, con un componente simbólico, que garantiza interpretabilidad, corrección y coherencia lógica. En los últimos años han proliferado arquitecturas que siguen el patrón “generación neuronal + verificación simbólica”: un LLM actúa como generador y un verificador determinista valida las salidas contra una base de conocimiento formal, rechazando o corrigiendo las propuestas inválidas [14]–[17]. Este patrón ha mostrado eficacia en tareas que requieren alta fiabilidad, como la extracción de información estructurada, el razonamiento matemático o la generación de código seguro [18]–[20].

Trasladar este enfoque a AutoML resulta natural: el LLM actúa como generador de hipótesis (pipelines candidatos) y un validador simbólico inspecciona cada pipeline verificando que los componentes pertenezcan a un esquema controlado, que los tipos de entrada y salida sean compatibles, que los hiperparámetros estén dentro de sus dominios válidos, y que la secuencia de pasos conforme un flujo ejecutable. De esta forma, se preserva la creatividad del modelo neuronal mientras se eliminan las alucinaciones estructurales.

1.1.3 Justificación práctica y científica

Desde un punto de vista práctico, la estrategia propuesta busca reducir el número de evaluaciones empíricas —la fase más costosa en tiempo de cómputo — aprovechando dos mecanismos complementarios. Por un lado, la base de conocimiento experiencial permite recuperar pipelines que ya demostraron ser eficaces en datasets con características similares, proporcionando al LLM un contexto informado que evita partir de cero. Por otro lado, el validador simbólico descarta, antes de cualquier ejecución, aquellos pipelines que contienen componentes inexistentes, hiperparámetros fuera de rango o incompatibilidades de tipos, eliminando así el desperdicio de recursos en configuraciones inviables. La combinación de ambos mecanismos concentra la búsqueda en regiones prometedoras del espacio de soluciones y acerca el rendimiento del sistema automático al de un experto humano que razona sobre qué técnicas aplicar en función de las propiedades de los datos.

Desde la perspectiva científica, el trabajo contribuye a cerrar la brecha entre el meta-aprendizaje implícito de los LLMs y los mecanismos explícitos de transferencia de conocimiento en AutoML. Al formalizar una arquitectura neuro-simbólica que integra recuperación aumentada por generación (RAG),

razonamiento en lenguaje natural y verificación formal, se avanza hacia sistemas AutoML que no solo memorizan configuraciones, sino que comprenden y justifican sus decisiones.

1.2 Formulación del Problema

El problema científico que aborda esta investigación se concreta en la siguiente pregunta:

¿En qué medida una estrategia neuro-simbólica de meta-aprendizaje para AutoML, que integra de forma incremental un LLM generador, un verificador simbólico, un ciclo de razonamiento iterativo y una base de conocimiento experiencial, permite aproximar —o incluso igualar— los mejores pipelines conocidos para un conjunto de problemas de referencia, reduciendo al mismo tiempo el número de evaluaciones necesarias frente a los enfoques clásicos de AutoML?

Esta pregunta se desglosa en las siguientes dimensiones:

1. Establecer un punto de partida mediante la combinación mínima LLM + verificador simbólico en régimen zero-shot, sin acceso a experiencias previas más allá del conocimiento implícito que el LLM posee como meta-modelo, y medir su distancia a los resultados de referencia.
2. Añadir un procedimiento de razonamiento iterativo guiado por el LLM, que a partir del historial de pipelines evaluados y del conocimiento semántico del modelo proponga mejoras sucesivas, y cuantificar el salto de rendimiento que este componente introduce.
3. Incorporar una base de conocimiento poblada con experiencias previas reales (meta-características, pipelines exitosos, rendimientos y, de forma esencial, los razonamientos en lenguaje natural que los justifican), y analizar cómo la recuperación de dichas experiencias enriquece el contexto del LLM y potencia tanto la generación inicial como el refinamiento iterativo.
4. Determinar, mediante experimentación controlada sobre problemas del repositorio OpenML, la contribución individual de cada componente al rendimiento final, utilizando como referencia los mejores resultados documentados para dichos problemas y comparando asimismo con sistemas AutoML consolidados.

1.3 Hipótesis de Partida

Se formula la siguiente hipótesis de trabajo:

Una estrategia de meta-aprendizaje neuro-simbólico que combine un LLM generador, un verificador simbólico para garantizar la corrección de los pipelines, un ciclo de razonamiento iterativo que explota las explicaciones almacenadas y una base de conocimiento de experiencias previas, permitirá alcanzar pipelines de clasificación cuyo rendimiento se aproxime significativamente a los mejores resultados conocidos en benchmarks de OpenML, superando a la generación zero-shot sin asistencia y al meta-aprendizaje clásico basado únicamente en similitud de meta-características.

La hipótesis se apoya en el supuesto de que cada incremento —validación simbólica, razonamiento iterativo y recuperación de experiencias— aporta una mejora medible, y que el efecto conjunto de los tres componentes permite concentrar la búsqueda en las regiones más prometedoras del espacio de soluciones, reduciendo así el costo computacional sin sacrificar la calidad de las soluciones encontradas.

1.4 Objetivos

El **objetivo general** de este trabajo es diseñar una estrategia computacional de meta-aprendizaje para AutoML basada en el paradigma neuro-simbólico, que integre un LLM generador, un verificador simbólico, un ciclo de razonamiento iterativo y una base de conocimiento experiencial, y evaluar en qué medida dicha integración permite aproximarse a los mejores pipelines conocidos en problemas de referencia.

Para alcanzar este objetivo se definen los siguientes **objetivos específicos**:

1. Analizar el estado del arte en AutoML, modelos de lenguaje de gran escala, paradigma neuro-simbólico y su intersección, identificando las limitaciones que justifican la propuesta.
2. Formalizar una arquitectura neuro-simbólica que articule los componentes esenciales: un LLM como generador de pipelines, un validador simbólico que garantice la corrección sintáctica y semántica de los candidatos, un ciclo de optimización que explore el espacio de búsqueda de algoritmos y sus hiperparámetros guiado por las explicaciones generadas por el propio modelo, y una base de meta-conocimiento que almacene y recupere experiencias previas (meta-características, pipelines, rendimientos y razonamientos).
3. Implementar un prototipo funcional de la estrategia sobre el ecosistema Scikit-Learn, empleando herramientas de código abierto para el LLM, y desarrollando de forma manual tanto la base de conocimiento como el módulo de verificación simbólica.
4. Evaluar el prototipo sobre problemas seleccionados del repositorio OpenML mediante un plan experimental, comenzando por la configuración mínima (LLM + verificador en régimen zero-shot, sin información contextual ni conocimiento adicional) y añadiendo sucesivamente el razonamiento iterativo y la base de conocimiento, utilizando como referencia los mejores pipelines documentados para dichos problemas.
5. Documentar los resultados experimentales, extraer conclusiones sobre la viabilidad y efectividad de la estrategia, y proponer líneas de trabajo futuro que contemplen la integración del enfoque en frameworks de AutoML heterogéneo como AutoGOAL.

1.5 Metodología

Para el desarrollo de la presente investigación se adoptó un enfoque cuantitativo, de tipo experimental y comparativo, en concordancia con el método científico. Francis Bacon, en su obra *El Avance del Conocimiento*, define este método a partir de etapas que incluyen la observación, la formulación de hipótesis, la experimentación, la demostración o refutación y el establecimiento de conclusiones [21] (NO ME SIRVE MUCHO CITAR A FRANCIS BACON; PERO ES INDISPENSABLE LA PRIMERA ORACION DE ESTE PARRAFO Y LA ULTIMA). La aplicación de este marco general es factible en las investigaciones relacionadas con la Ciencia de la Computación, y ha guiado el presente trabajo.

(ARREGLA INCONSISTENCIAS: En particular, se aplicó el método hipotético-deductivo para la elaboración de la hipótesis central, la cual fue desglosada en hipótesis específicas comprobables. La revisión bibliográfica se sustentó en el método histórico-lógico, lo que permitió estudiar trabajos previos, identificar sus aspectos positivos y negativos, y establecer los antecedentes que justifican el objetivo general y los objetivos específicos. El método inductivo-deductivo facilitó la identificación de tendencias actuales y problemas abiertos en el campo de AutoML y el meta-aprendizaje neuro-simbólico. La comparación-clasificación es la base de los experimentos diseñados para contrastar la propuesta con las alternativas existentes y a través de una demostración a través de experimentos, junto con técnicas estadísticas, se utilizó para la validación de los resultados y los estudios comparativos.)

El trabajo se organizó en las siguientes fases consecutivas:

1. **Revisión sistemática del estado del arte**: Se realizó una búsqueda exhaustiva de literatura en las áreas de AutoML, LLMs, meta-aprendizaje y paradigma neuro-simbólico, abarcando tanto artículos fundacionales como contribuciones recientes (2020-2026). Se analizaron críticamente las capacidades y limitaciones de cada enfoque, lo que permitió identificar la brecha que motiva la propuesta.
2. **Formalización de la estrategia**: A partir de los hallazgos de la revisión, se diseño una arquitectura modular que especifica las interfaces entre el LLM generador, el módulo de recuperación de experiencias, el validador simbólico, y el bucle de razonamiento iterativo. La estrategia se describió formalmente mediante diagramas de flujo y pseudocódigo.
3. **Implementación del prototipo**: Se desarrolló un prototipo en Python que integra:
   - Un espacio de búsqueda de pipelines compuesto por algoritmos de preprocesamiento, reducción de dimensionalidad y clasificación de Scikit-Learn, incluyendo la definición explícita de los hiperparámetros permitidos y sus dominios (rangos continuos, discretos y valores categóricos)
   - Un sistema de recuperación de experiencias basado en los vectores de meta-características. Para cada dataset procesado, se almacenan sus meta-características normalizadas y se asocian a la tupla de experiencia correspondiente (pipeline, rendimiento, razonamiento). La similitud entre un nuevo dataset y los almacenados se calcula mediante una métrica de distancia directamente sobre los vectores, sin utilizar una base de datos vectorial externa, lo que permite recuperar los k vecinos más cercanos y enlazar eficientemente con el conocimiento previo.
   - Un validador simbólico que comprueba la pertenencia de los nombres de componentes al vocabulario definido, la compatibilidad de tipos entre pasos consecutivos, la pertenencia de los hiperparámetros a sus dominios especificados y la validez de la secuencia del pipeline
   - Un módulo central que coordina el flujo completo: a partir de un nuevo dataset, recupera las experiencias más similares, construye el *prompt* enriquecido para el LLM, recibe las propuestas generadas, las somete al validador simbólico (con reintentos de corrección si es necesario) y evalúa válidos mediante validación cruzada.
4. **Diseño experimental**: Se seleccionaron conjuntos de datos del repositorio OpenML, asegurando diversidad en dimensionalidad, número de instancias, clases y desbalance. Se definió un plan experimental incremental, que comienza con la configuración mínima (LLM + verificador en régimen zero-shot) y añade sucesivamente el razonamiento iterativo y la base de conocimiento. Se estableció como métrica principal: exactitud (*accuracy*) y número de pipelines evaluados, utilizando como referencia los mejores pipelines documentados para dichos problemas. Cada experimento se repitió, al menos, 30 veces para obtener intervalos de confianza.
5. **Experimentación y análisis de resultados**: Se ejecutaron los experimentos comparativos. Se analizó la significancia estadística de las diferencias observadas y se interpretaron los resultados a la luz de la literatura revisada.

El resto del documento se ha organizado de la siguiente manera. El **Capítulo 2** presenta el estado del arte de los temas relacionados, incluyendo los fundamentos de AutoML, los modelos de lenguaje de gran escala, el paradigma neuro-simbólico y la integración de LLMs en sistemas AutoML. El **Capítulo 3** describe en detalle la propuesta de estrategia computacional, formalizando los componentes y su interacción. El **Capítulo 4** aborda la implementación del prototipo, el diseño experimental y la presentación y discusión de los resultados obtenidos. Finalmente, el documento se cierra con las conclusiones, las recomendaciones para trabajo futuro y las referencias bibliográficas.

Referencias

[1] H. Touvron *et al.*, “LLaMA: Open and Efficient Foundation Language Models,” *arXiv preprint arXiv:2302.13971*, 2023.

[2] S. Zhu *et al.*, “AutoML-GPT: Automatic Machine Learning with GPT,” *arXiv preprint arXiv:2305.02499*, 2023.

[3] Y. Zhang *et al.*, “AutoML-Agent: A Multi-Agent LLM Framework for Full-Pipeline AutoML,” *arXiv preprint*, 2024.

[4] Z. Ji *et al.*, “Survey of Hallucination in Natural Language Generation,” *ACM Comput. Surv.*, vol. 55, no. 12, pp. 1–38, 2023.

[5] S. S. Li *et al.*, “SoK: Exploring Hallucinations and Security Risks in AI-Assisted Software Development with Insights for LLM Deployment,” *arXiv preprint*, 2024.

[6] C. Thornton *et al.*, “Auto-WEKA: Combined Selection and Hyperparameter Optimization of Classification Algorithms,” in *Proc. 19th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2013, pp. 847–855.

[7] F. Hutter, L. Kotthoff, and J. Vanschoren, Eds., *Automated Machine Learning: Methods, Systems, Challenges*. Springer, 2019.

[8] R. S. Olson *et al.*, “Evaluation of a Tree-Based Pipeline Optimization Tool for Automating Data Science,” in *Proc. Genet. Evol. Comput. Conf.*, 2016, pp. 485–492.

[9] M. Feurer *et al.*, “Initializing Bayesian Hyperparameter Optimization via Meta-Learning,” in *Proc. AAAI Conf. Artif. Intell.*, 2015, pp. 1128–1135.

[10] M. Feurer *et al.*, “Auto-Sklearn 2.0: Hands-free AutoML via Meta-Learning,” *J. Mach. Learn. Res.*, vol. 21, no. 1, pp. 1–6, 2020.

[11] A. Tornede *et al.*, “LLMs as In-Context Meta-Learners for Model and Hyperparameter Selection,” *arXiv preprint*, 2024.

[12] Z. Jiang *et al.*, “Large Language Models for Constructing and Optimizing Machine Learning Workflows: A Survey,” *arXiv preprint*, 2024.

[13] Z. Xu, S. Jain, and M. Kankanhalli, “Hallucination is Inevitable: An Innate Limitation of Large Language Models,” *arXiv preprint arXiv:2401.11817*, 2024.

[14] S. Chen *et al.*, “PEIRCE: Unifying Material and Formal Reasoning via LLM-Driven Neuro-Symbolic Refinement,” in *Proc. ACL*, 2025.

[15] L. De Raedt *et al.*, “Advancing Symbolic Integration in Large Language Models: Beyond Conventional Neurosymbolic AI,” *arXiv preprint*, 2025.

[16] L. Pan *et al.*, “Logic-LM: Empowering Large Language Models with Symbolic Solvers for Faithful Logical Reasoning,” in *Findings of EMNLP*, 2023.

[17] A. d’Avila Garcez *et al.*, “Neuro-Symbolic Artificial Intelligence: Towards Improving the Reasoning Abilities of Large Language Models,” in *Proc. IJCAI*, 2025.

[18] D. Varghese *et al.*, “Neurosymbolic Information Extraction from Transactional Documents,” in *Proc. EMNLP*, 2024.

[19] M. S. Kim *et al.*, “VeriCoT: Neuro-symbolic Chain-of-Thought Validation via Logical Consistency Checks,” *arXiv preprint arXiv:2511.04662*, 2025.

[20] T. Nguyen *et al.*, “Eidoku: A Neuro-Symbolic Verification Gate for LLM Reasoning via Structural Constraint Satisfaction,” *arXiv preprint arXiv:2512.20664*, 2025.

[21] J. Snoek, H. Larochelle, and R. P. Adams, “Practical Bayesian Optimization of Machine Learning Algorithms,” in *Adv. Neural Inf. Process. Syst.*, 2012, pp. 2951–2959.

[22] F. Hutter, H. H. Hoos, and K. Leyton-Brown, “Sequential Model-Based Optimization for General Algorithm Configuration,” in *Int. Conf. Learn. Intell. Optim.*, 2011, pp. 507–523.

[23] M. Feurer and F. Hutter, “Hyperparameter Optimization,” in *Automated Machine Learning*, Springer, 2019, pp. 3–38.

[24] T. Elsken, J. H. Metzen, and F. Hutter, “Neural Architecture Search: A Survey,” *J. Mach. Learn. Res.*, vol. 20, no. 55, pp. 1–21, 2019.

[25] A. Estévez *et al.*, “Descubrimiento Automático de Flujos de Aprendizaje de Máquinas basado en Gramáticas Probabilísticas,” *Tesis doctoral*, Universidad de La Habana, 2020.

[26] A. Estévez *et al.*, “AutoGOAL: A Framework for Heterogeneous AutoML,” en preparación.

[27] M. O’Neill and C. Ryan, “Grammatical Evolution,” *IEEE Trans. Evol. Comput.*, vol. 5, no. 4, pp. 349–358, 2001.

[28] J. Vanschoren, “Meta-Learning: A Survey,” *arXiv preprint arXiv:1810.03548*, 2018.

[29] R. Vilalta and Y. Drissi, “A Perspective View and Survey of Meta-Learning,” *Artif. Intell. Rev.*, vol. 18, pp. 77–95, 2002.

[30] B. Bischl *et al.*, “pymfe: Python Meta-Feature Extractor,” *J. Open Source Softw.*, vol. 4, no. 40, p. 1562, 2019.

[31] J. Vanschoren, “Meta-Learning,” in *Automated Machine Learning*, Springer, 2019, pp. 35–62.

[32] A. Pimentel *et al.*, “Dynamic Design of Machine Learning Pipelines via Metalearning,” in *Proc. ECML PKDD*, 2021.

[33] A. Vaswani *et al.*, “Attention Is All You Need,” in *Proc. NeurIPS*, 2017.

[34] J. Devlin *et al.*, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *Proc. NAACL-HLT*, 2019.

[35] A. Radford *et al.*, “Improving Language Understanding by Generative Pre-Training,” OpenAI, 2018.

[36] T. Brown *et al.*, “Language Models are Few-Shot Learners,” in *Proc. NeurIPS*, 2020.

[37] A. Chowdhery *et al.*, “PaLM: Scaling Language Modeling with Pathways,” *arXiv preprint arXiv:2204.02311*, 2022.

[38] H. Touvron *et al.*, “LLaMA: Open and Efficient Foundation Language Models,” *arXiv preprint arXiv:2302.13971*, 2023.

[39] OpenAI, “GPT-4 Technical Report,” *arXiv preprint arXiv:2303.08774*, 2023.

[40] G. Team, “Gemini: A Family of Highly Capable Multimodal Models,” *arXiv preprint arXiv:2312.11805*, 2023.

[41] S. Yao *et al.*, “ReAct: Synergizing Reasoning and Acting in Language Models,” *arXiv preprint arXiv:2210.03629*, 2022.

[42] L. Ouyang *et al.*, “Training Language Models to Follow Instructions with Human Feedback,” in *Proc. NeurIPS*, 2022.

[43] R. Rafailov *et al.*, “Direct Preference Optimization: Your Language Model is Secretly a Reward Model,” *arXiv preprint arXiv:2305.18290*, 2023.

[44] J. Wei *et al.*, “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” in *Proc. NeurIPS*, 2022.

[45] T. Kojima *et al.*, "Large Language Models are Zero-Shot Reasoners," in *Proc. NeurIPS*, 2022.

[46] M. Chen *et al.*, "Evaluating Large Language Models Trained on Code," *arXiv preprint arXiv:2107.03374*, 2021.

[47] B. Roziere *et al.*, "Code Llama: Open Foundation Models for Code," *arXiv preprint arXiv:2308.12950*, 2023.

[48] R. Li *et al.*, "StarCoder: May the Source be with You!," *arXiv preprint arXiv:2305.06161*, 2023.

[49] T. Schick *et al.*, "Toolformer: Language Models Can Teach Themselves to Use Tools," *arXiv preprint arXiv:2302.04761*, 2023.

[50] A. Tornede *et al.*, "LLMs as In-Context Meta-Learners for Model and Hyperparameter Selection," *arXiv preprint*, 2024.

[51] Y. Benajiba *et al.*, "A Theoretical Survey of Transformer Limitations: Circuit Complexity, Approximation, and Communication," in *Proc. ACL*, 2026.

[52] M. Ballesteros *et al.*, "Transformers: A Theoretical Survey of Limitations," in *Proc. ACL*, 2026.

[53] E. M. Bender *et al.*, "On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?," in *Proc. FAccT*, 2021, pp. 610–623.

[54] A. B. M. M. Rahaman *et al.*, "Large Language Models: A Structured Taxonomy and Review of Challenges, Limitations, Solutions, and Future Directions," *TechRxiv*, 2024.

[55] A. d'Avila Garcez *et al.*, "Neurosymbolic AI: The 3rd Wave," *Artif. Intell.*, vol. 319, p. 103948, 2023.

[56] A. S. d'Avila Garcez *et al.*, "Neuro-Symbolic Artificial Intelligence: Towards Improving the Reasoning Abilities of Large Language Models," in *Proc. IJCAI*, 2025.

[57] D. Silver *et al.*, "Mastering the Game of Go with Deep Neural Networks and Tree Search," *Nature*, vol. 529, pp. 484–489, 2016.

[58] Y. Chen *et al.*, "NNGPT: Rethinking AutoML with Large Language Models," *arXiv preprint*, 2024.

[59] Z. Wang *et al.*, "LB-MCTS: Synergizing Large Language Models and Bayesian Optimization for Efficient CASH," *arXiv preprint*, 2024.

[60] D. Jeong *et al.*, "AutoRAG: Automated Framework for Optimization of Retrieval-Augmented Generation Pipeline," in *Proc. EMNLP*, 2024.